

# Bayes decision rule

## 什么是贝叶斯公式

已知事件A,B发生的概率分别为  $P(A)$ ,  $P(B)$ , 那么两者的相互的条件概率(conditional probability)分别可以表示为:  $P(A|B)$ ,  $P(B|A)$ .

$$P(A|B) = \frac{P(A \& B)}{P(B)} \text{ 得出 } P(A \& B) = P(A|B) * P(B)$$

$$P(B|A) = \frac{P(A \& B)}{P(A)} \text{ 得出 } P(A \& B) = P(B|A) * P(A)$$

所以可以推出  $\Rightarrow P(A|B) * P(B) = P(B|A) * P(A)$  稍加变形就是贝叶斯公式:

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}$$

## 贝叶斯公式的小例子

假设以硬币举例

- 假设已知硬币正面, 反面朝上的概率分别为  $P(\text{正})$   $P(\text{反})$  叫做 **先验概率(Priori Probabilities)**
- 在已知先验概率的情况下, 求在硬币为某一属性  $X$  下, 正面的概率为:  $P(\text{正} | \text{硬币} = X)$  叫做后验概率(**posterior probability**)

例如, 我们现在抛硬币, 且知道硬币有三种类型(数据属性)  $c_1 = \text{大}$ ,  $c_2 = \text{中}$ ,  $c_3 = \text{小}$ , 得到的结果为正, 反(输出类型), 其中30次反面, 70次正面. 在反面时, 小硬币出现6次. 正面时, 小硬币出现7次

所以我们的任务就是求的后验概率 当观察到硬币为小硬币, 其结果分为正反的概率, 根据贝叶斯公式:

$$P(\text{正} | \text{硬币} = \text{小}) = \frac{P(\text{硬币} = \text{小} | \text{正面}) * P(\text{正面})}{P(\text{硬币} = \text{小})}$$

$$P(\text{硬币} = \text{小}) = \frac{13}{100} = 0.13$$

$$P(\text{硬币} = \text{小} | \text{正}) = \frac{7}{70} = 0.1$$

$$P(\text{正}) = \frac{70}{100}$$

所以可以求出概率 = 0.54, 说明当硬币是小硬币的情况下, 它抛出正面的概率为**0.54**

## 贝叶斯方法在机器学习分类中的应用

这种方法假设我们已经完全知道了每个分类的 **先验概率(Priori Probabilities)**, 即我们知道如果结果有  $C$  类, 那么  $P(c_1), \dots, P(c_c)$  我们都知道.

这种方法应用到机器学的分类中本质就是需要: 根据先验概率(建模时获得), 在观察到新的数据的属性  $X$  时候, 求的它的后验概率的过程

## bayes 算出所有类的后验概率

即对于所有的  $\{c_1, \dots, c_w\} \in \text{Class}$  :

然后根据所有的后验概率找到最大的那一个  $\text{Max } P(c_w | X)$ , 记为该数据属性的分类  $c_w$

$$P(c_i | X) = \frac{P(X|c_i) * P(c_i)}{P(X)}$$

其中  $P(X)$  的概率都一样 :  $P(X) = \sum_{j=1}^C P(X|c_i) * P(c_i)$

所以有了结论, 我们将 $X$ 归于类 $c_i$ 当且仅当 (Bayes' rule minimum error):

$$P(x|c_i) * P(c_i) > p(x|c_k) * P(c_k) \quad k = 1, \dots, w \quad k \neq i$$

## Bayes 方法优缺点

### 优点

- 贝叶斯决策理论是最优的, 因为只要观测到数据属性为  $X$ , 然后选择后验概率最大的结果, 就可以**最小化预测错误的概率(Bayes decision rule for minimum risk)**可以证明. 这个结论对所有的观测值  $X \in \text{All\_features}$  都成立, 从而可以保证预测错误的概率最小, 从而达到最优.
- 可以调节先验概率和观测现象之间的平衡, 即有了Bayes方法可以使得预测结果不仅仅依赖于先验概率, 还一部分取决于观测的现象(数据属性  $X$ )

### 缺点

- 我们通常是无法获得先验概率(prior class), 条件概率(conditional densities)等计算要件. 要获得只有从数据中进行估算(比如上面抛硬币的例子), 所有肯定和真实的概率分布有误差.
- 往往在实际中, 要观察的特征不知一个(不仅仅为大中小), 可能会面临成百上千个特征属性. 所以在计算的时候, 会遇到**维度灾难(the curse of dimensionality)**, 时候计算的数值很不稳定. 所以才会发展出朴素贝叶斯方法的平滑(smoothing)去解决这个问题